

Analiza zdrowia snu

Sleep Health & Daily Performance Dataset

Klasyfikacja ryzyka zaburzeń snu | Eksperyment 1: Undersampling | Eksperyment 2: Selekcja cech

Autorzy: Tomasz Adamczyk 279417, Paweł Suchodolski 279419

100 000

próbek

30

cech

4

klasy

2

eksperymenty

O zbiorze danych

- 100 000 rekordów, 30 cech
- Dane syntetyczne dotyczące zdrowia snu i codziennych nawyków
- Zmienna docelowa: sleep_disorder_risk (4 klasy)
- Brak wartości brakujących
- Cechy: wiek, czas snu, jakość snu, stres, tętno, kroki, REM, fazy snu i inne

Healthy

n = 54 156



Mild

n = 33 479



Moderate

n = 8 299







Severe

n = 4 066



Wizualizacja zbioru danych



Eksperymenty

01

Stopniowy undersampling

Badamy jak stopniowe redukowanie nad reprezentowanych klas wpływa na jakość klasyfikacji (BAC). Porównujemy 3 klasyfikatory w 4 wariantach danych.

02

Wpływ cech na klasyfikację

Drop-one ablation + Forward selection. Szukamy które cechy są kluczowe dla DT i jak minimalny zbiór cech wypada względem pełnego.

Eksperyment 1 — Stopniowy undersampling

Brak

Oryginalne dane
100 000 próbek

54 156/33 479/8 299/4 066

Under k1

Najliczniejsza
→ poziom 2.

33 479/33 479/8 299/4 066

Under k2

2 najliczniejsze
→ poziom 3.

8 299/8 299/8 299/4 066

Under k3

Pełne wyrównanie
→ poziom najmniejszej

4 066/4 066 /4 066/4 066

Klasyfikatory:

GaussianNB


KNeighborsClassifier

DecisionTree

Analiza statystyczna: test Shapiro-Wilka (normalność) + sparowany t-test ($\alpha = 0.05$)

Eksperyment 1 — Wyniki

Wariant	GNB	KNN	DT
Brak	0.634	0.352	0.759
Under k1	0.633	0.362	0.756
Under k2	0.636	0.395	0.727
Under k3	0.634	0.403	0.703



Wnioski z analizy statystycznej (t-test, $\alpha = 0.05$):

DT: Brak vs Under k1 — brak istotnej różnicy ($p = 0.145$)


DT: Brak vs Under k2/k3 — istotna różnica, lepszy wariant: Brak

KNN: wszystkie kroki undersamplingu istotnie lepsze od Braku

Eksperyment 1 — Rozkład próbek po undersamplingu

sleep_duration_hrs vs sleep_quality_score (wg klasy)

Rozkład próbek w poszczególnych krokach undersamplingu



Eksperyment 2 — Wpływ cech na klasyfikację


Faza A — Drop-one ablation

- Trenujemy DT na pełnym zbiorze (baseline: BAC = 0.760)
- Usuwamy każdą cechę z osobna i mierzymy zmianę BAC (Δ)
- $\Delta < -0.005 \rightarrow$ cecha ważna | $\Delta > +0.005 \rightarrow$ cecha zbędna
- 30 cech = 30 osobnych eksperymentów

Faza B — Forward selection


- Startujemy od pustego zbioru cech
- W każdym kroku dodajemy cechę dającą największy wzrost BAC
- Zatrzymujemy się gdy BAC przestaje rosnąć
- Wynik: optymalny minimalny podzbiór cech

Eksperyment 2 — Wpływ cech na klasyfikację, wykres




Eksperyment 2 — Wpływ cech na klasyfikację, wykres 2

Eksperyment 2: Wpływ wyboru cech na klasyfikację



Eksperyment 2A — Drop-one

Eksperyment 2A: Zmiana dokładności po usunięciu jednej cechy (DT)
Czerwony = cecha ważna (jej brak szkodzi) | Zielony = cecha zbędna/szkodliwa



Eksperyment 2A — Drop-one, analiza

Top 5 najważniejszych cech (największy spadek BAC po usunięciu):


mental_health_condition	-0.155	
sleep_duration_hrs	-0.116	
bmi	-0.115	
sleep_latency_mins	-0.067	
wake_episodes_per_night	-0.064	

Wniosek statystyczny (t-test):

Baseline vs bez mental_health_condition — $t = 69.5$, $p < 0.001$ → różnica istotna statystycznie, lepszy: baseline

Eksperyment 2B — Forward selection

Eksperyment 2B: Forward selection — wzrost dokładności wraz z dodawaniem cech (DT)



Eksperyment 2B — Forward selection, analiza

Kluczowe wyniki:

14 cech w optymalnym podzbiorze

0.776 BAC optimum (krok 14)

+0.016 zysk vs pełny zbiór (0.760)

Optymalny podzbiór (14 cech):

`sleep_quality_score, mental_health_condition, felt_rested, bmi, sleep_duration_hrs, sleep_latency_mins, wake_episodes_per_night, stress_score, alcohol_units_before_bed, shift_work, rem_percentage, age, caffeine_mg_before_bed, exercise_day`

Podsumowanie

Eksperyment 1 — Undersampling

DT osiąga najwyższe BAC bez undersamplingu (0.759)

KNN znacząco zyskuje na balansowaniu — wszystkie różnice istotne statystycznie

GNB stabilny niezależnie od stopnia balansowania

Pełne wyrównanie (k3) nie zawsze pomaga — dla DT istotnie obniża wyniki

Eksperyment 2 — Selekcja cech

Najważniejsza cecha: mental_health_condition ($\Delta = -0.155$)

14 z 30 cech wystarczy do osiągnięcia optimum (BAC = 0.776)

Optymalny podzbiór nieznacznie bije pełny zbiór (+0.016 BAC)

Wiele cech neutralnych — ich usunięcie nie wpływa na wynik